




CITATION PREDICTION CHALLENGE

Σακελλαρίου Ιωάννα 5125
Μουσελίμη Αμαλία-Γεωργία 5074
Επεξεργασία Φυσικής Γλώσσας



Εισαγωγή

- Υλοποίηση προβλήματος πρόβλεψης παραπομπών (link prediction)
- Χρήση δεδομένων από abstracts, authors, citations
- Στόχος: Να προβλέψουμε αν ένα άρθρο παραπέμπει σε άλλο άρθρο

Δεδομένα

Χρησιμοποιήσαμε:

- abstracts.txt: περιλήψεις άρθρων
- authors.txt: συγγραφείς ανά άρθρο
- edgelist.txt: πραγματικές παραπομπές
- test.txt: ζεύγη προς πρόβλεψη

Προεπεξεργασία

- Καθαρισμός και φόρτωση δεδομένων
- Κατασκευή κατευθυνόμενου γράφου G με NetworkX
- Δημιουργία ζευγών άρθρων (αρνητικών δειγμάτων)

Εξαγωγή Χαρακτηριστικών Γράφου

- Cosine similarity με Sentence-BERT
- Common Neighbors (CN): Αριθμός κοινών γειτόνων
- Common Authors: Ομοιότητα συγγραφέων
- Preferential Attachment (PA): Προτιμητική σύνδεση

Μοντέλα

Χρησιμοποιήσαμε:

- **PyTorch** (Feedforward Νευρωνικό Δίκτυο)
 - Καλή απόδοση
 - Χαμηλό *log loss*
 - Σταθερή γενίκευση

Άλλες δοκιμές:

- XGBoost για αρχική υλοποίηση
- LightGBM για γρηγορότερη εκπαίδευση

Πειραματικά Αποτελέσματα

- **TF-IDF & LightGBM: Log Loss ~0.19**
 - Γρήγορη λύση, χαμηλή ακρίβεια
- **SBERT & XGBoost: Log Loss ~0.17**
 - Καλή ακρίβεια, αργή
- **SBERT & XGBoost & Hard Negatives: Log Loss ~0.165**
 - Βελτίωση γενίκευσης, υψηλό κόστος
- **Τελικό Validation Log Loss με epochs: ~0.14**
 - Βέλτιστη απόδοση, καλή ισορροπία

Τεχνικές Βελτιστοποίησης

- Caching με .npy αρχεία
- Batch Processing
 - *Batches των 100.000 ζεύγων*
- Εγγραφή προσωρινών αρχείων στον δίσκο
 - *Χρήση pickle για ταχύτητα αποθήκευσης/φόρτωσης*

Συμπεράσματα

- **Sentence-BERT embeddings** >> πιο ακριβή από TF-IDF, αλλά απαιτούν ισχυρό υπολογισμό.
- **Γραφικά χαρακτηριστικά (neighbors, degree)** >> βελτιώνουν την πρόβλεψη.
- **Hard negatives** >> καλύτερη γενίκευση, αλλά πιο βαρύ training.
- **PyTorch FFNN** >> ιδανικό για πλούσια, υψηλών διαστάσεων features.
- **LightGBM/XGBoost** >> γρήγορα, αλλά προτιμώνται για απλούστερα δεδομένα.

Ευχαριστούμε για την προσοχή σας!